Aleksandra Wroblewska, Anastasia Zakharova, Hugo Meinhof, Jana Lauruschkus

February 11, 2024

1 Einleitung

Dieser Report gibt einen Überblick über die Bearbeitung der Klassifikationsaufgabe des AES-Projekts. Die Klassifikation ist ein Teilbereich des Maschinellen Lernens. Maschinelles Lernen lässt sich grob in drei verschiedene Ansätze einteilen: Überwachtes, unüberwachtes und bestärkendes Lernen. Klassifikation fällt unter überwachtes Lernen, bei dem ein Trainingsdatensatz von Menschen annotiert wird und ein Testdatensatz verwendet wird, um die gewünschte Klasse abzuleiten. Die Klassen in der Klassifikation sind ordinalskaliert, was bedeutet, dass sie diskret sind und sich nicht überschneiden. Die Aufgabe eines Klassifikator besteht nun darin, unstrukturierte, zuvor ungesehene Daten automatisch den vordefinierten Klassen zuzuordnen.(Klein, n.d.) Da sich die Benotung von Essays ohne Input von Vorverarbeitungsprozessen in anderen Gruppen als schwer erwies, haben wir zwei andere Ansätze implementiert, die das Ziel haben dem Essay einen Flesch-Reading-Score(van de Rakt, 2019) oder einen Mittelwert zuzuweisen. Hierfür muss zu aller erst das Dataset vorverarbeitet werden. Dies beinhaltet die Bereinigung von Text in den Essays und Filtern von ungültigen Daten. Auch das Aufteilen in Trainings- und Testsets wird hier miteinbezogen.

Zur Evaluation des Modells werden fünf Metriken genutzt.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

Die *Accuracy* gibt das Verhältnis zwischen korrekt klassifizierten Daten und der Gesamtzahl an Daten im Testsatz an. Umgangssprachlich wird hier angegeben, wie oft das Modell richtige Entscheidungen trifft. (Pratama, 2022, D, 2019)

$$Precision = \frac{TP}{TP+FP}$$

Die *Precision* zeigt an, wie viele der als positiv identifizierten Daten tatsächlich positiv sind. Also wird hier die Frage beantwortet, welche Daten, von denen die gefunden wurden, richtig sind. (D, 2019)

$$Recall = \frac{TP}{TP+FN}$$

Recall misst wie viele der tatsächlich positiven Instanzen korrekt identifiziert wurden. Es sind also alle relevanten Daten bekannt und nun soll festgestellt werden, wie viele davon das Modell erkennt. (Heloir, 2023)

$$F_1 = 2 \cdot \frac{precision \cdot recall}{precision + recall}$$

Der *F1-Score* ist ein harmonisches Mittel zwischen Precision und Recall. Je höher der F1-score, desto höher sind auch Precision und Recall des Modells. (Heloir, 2023)

Der *Loss* ist ein Maß für die Fehler, die das Modell macht. Für verschiedene Anwendungszwecke gibt es hier verschiedene Funktionen zur Berechnung. Eine Faustregel jedoch ist, je niedriger der Loss, desto mehr stimmen die Vorhesagen des Modells mit den tatsächlichen Labels überein. (Alake, 2023)

2 Diskussion der Aufgaben mit Beispielen

Zur Fertigstellung des Projektes wurden zwei Herangehensweisen verwendet. In der ersten Herangehensweise wurde das Dataset anhand der Flesch-Readability-Scores mit Labels kategorisiert. Die Originalunterteilung erfolgte in 10er-Schritten. Je niedriger der Wert, desto anspruchsvoller das Niveau des Textes.

Zu Beginn wurde ein Preprocessing des Essay-Datensatzes durchgeführt. Hierbei wurden regulär Ausdrücke angewendet, sowie Texte entfernt, die kürzer als 10 Zeichen waren. Darüber hinaus wurden manuell einige Dateien gelöscht, die während des Preprocessings nicht erkannt wurden - darunter Texte, die ausschließlich aus Sonderzeichen bestanden oder sehr kurz waren. Am Ende blieben von 1042 Essays 928 übrig.

Daraufhin wurden die Daten basierend auf ihren Flesch-Reading-Scores kategorisiert. Unsere nächste Idee bestand darin, jedem spezifischen Bewertungsbereich Beschriftungen zuzuweisen, um das Modell später anhand dieser Beschriftungen zu trainieren. Zuerst haben wir versucht, die ursprüngliche Skalierung von Flesch-Reading-Ease zu verwenden und jedem Bereich von 10 ein eindeutiges Label zuzuweisen. Auf diese Weise kamen wir auf 7 Labels (**1** steht für die am schwersten zu lesenden Texte und **7** für die am einfachsten zu lesenden). Die Labels **1** und **7** hatten jedoch jeweils weniger als 10 Texte, die Labels **2** und **5** weniger als 70 Texte, während die Labels **2** - **4** mehr als 200 Texte hatten. Wir haben uns dazu entschieden, die Labels **1,2** und **6,7** zu kombinieren, um einen besser nutzbaren Datensatz zu erhalten.

Da wir nun einen Datensatz mit 928 Texten und 5 Labels hatten, versuchten wir, unser Modell zu trainieren. Allerdings war der Datensatz immer noch sehr unausgewogen, fast genau die Hälfte der Texte befand sich unter dem

Label **3**. Anschließend haben wir den Datensatz manuell ausgeglichen und die Anzahl der Texte unter jedem stark vertretenen Label auf oder nahe an die minimale Menge des Labels **1**, mit nur 37 Texten, reduziert. Am Ende erhielten wir einen ausgewogenen Datensatz mit insgesamt 202 Texten, ca. 40 Texte zu jedem Label. Wir haben 70% des Datensatzes zum Trainieren und 30% zum Testen des Modells verwendet.

Daraufhin wurden die Ratings-Excel-Datei und die PDFs zusammengeführt, um weitere Informationen über die Essays zu erhalten.

Im nächsten Schritt wurde ein Klassifikator aufgebaut, wobei der Datensatz in Trainings- und Testgruppen aufgeteilt wurde. Support-Vektor-Maschinen- und Logistic Regression eignen sich am besten für die Klassifizierung von 2 Labels, daher haben wir verschiedene Labels paarweise getestet. Das Modell konnte jedes Label in mindestens einer der Einstellungen erfolgreich kategorisieren, wobei die SVM-Methode häufiger gute Ergebnisse lieferte.

Einige der besten Ergebnisse mit SVM für den Dataset mit Lesbarkeitsbewertung und Durchschnittswerten für Wörter/Sätze/Gesamteindruck:

	precision	recall	f1-score
1	1.000	0.556	0.714
3	0.636	1.000	0.778
accuracy			0.750

	precision	recall	f1-score
2	0.667	0.857	0.750
5	0.875	0.700	0.778
accuracy			0.765

	precision	recall	f1-score
2	0.875	0.875	0.875
4	0.889	0.889	0.889
accuracy			0.882

	precision	recall	f1-score
3	0.667	0.750	0.706
5	0.750	0.667	0.706
accuracy			0.706

In der zweiten Herangehensweise haben wir ein DistilBERT-Modell der Hugging Face-Bibliothek (HuggingFace, 2024b, HuggingFace, 2024a) geladen und für unsere Zwecke angepasst. DistilBERT (Sanh et al., 2019) ist eine komprimierte Version des BERT-Modells von Google, das speziell für die Verarbeitung von Textsequenzen entwickelt wurde und hierbei auch die Semantik und den Kontext von Wörtern berücksichtigt.

Die relevanten Python-Datein für diesen Ansatz sind *essay_dataset* und *B001*. In der Datei *essay_dataset* wird das Dataset geladen, das später für das Training verwendet wird. Auch diese Implementation ist von Hugging face übernommen worden (HuggingFace, 2020). Hier wird dem Nutzer die Möglichkeit gegeben, den Teil des Datensatzes auszuwählen, der für die jeweilige Aufgabenstellung am relevantesten ist. Für uns sind das die Mittelwerte, welche am Ende der Excel-Tabelle zu finden sind und die durchschnittliche Bewertungen von Inhalt, Sprache und Gesamteindruck abbilden.

In diesem Ansatz wird aber nicht nur mit der Excel-Datei gearbeitet, sondern auch mit dem Essay Datensatz, welche in einer JSON-Datei gespeichert sind. Die Essays werden mit der Methode _get_essays_json aus der json Datei in einer Liste von Dictionaries gespeichert, wobei jedes dictionary einem Essay entspricht. Die Bewertungen aus der Excel-Tabelle werden in einem Pandas DataFrame repräsentiert, wobei jede Zeile eine Bewertung darstellt. Durch die Kombination beider Datensätze, werden gültige IDs gefunden und Beispiele erzeugt. Andere Bewertungen für die Essays, wie Flesch-Reading Score, werden in diesem Teil aber nicht mehr miteinbezogen. Auch der Text wird nicht weiter vorverarbeitet, sondern es wird mit den Rohdaten der Essays gearbeitet.

Darüber hinaus wird in diesem Teil des Ansatzes sichergestellt, dass das Dataset in Trainings- Testset gesplittet wird. Im Gegensatz zum ersten Modell gibt es hier auch ein Validierungsset.

Nachdem der Datensatz erstellt wurde, wird er in der Implementierung der "*B001*"-Datei geladen und weiterverarbeitet. Hier konzentrieren wir uns auf die Bewertung der Excel-Spalte MW_B001, die einen Mittelwert des ersten Gesamteindrucks darstellt, und interpretieren dies als Readability Score, welchen das Modell letzendlich vorhersagen soll. Natürlich könnte man hier aber jeden belieben Mittelwert der Excel-Tabelle als Bewertungsscore nehmen und damit weiterarbeiten. Zu kritisieren an diesem Ansatz ist, dass die Bewertung mit Mittelwerten teilweise von der Gruppenzugehörigkeit abhängig zu sein scheint. Es gibt einige Fälle, in denen ein sehr kurzes, beinahe inhaltsloses Essay aus der Control Group genau den gleichen Mittelwert zugewiesen bekommt, wie ein längerer, verständlicherer Text aus einer anderen Gruppe. Die vorherzusagenen Labels werden in 0.5-Schritten von 1 bis 5 festgelegt. In der Excel-Tabelle sind auch Mittelwerte von 8 zufinden, welche wir jedoch ignorieren, da für diese keine Erläuterung vorliegt. Sonst werden in dieser Datei noch Parameter für das Training festgelegt, die Lernrate, Batch-Größe und Epochenanzahl umfassen. Zuletzt wird ein Trainer initialisiert, der das Modell auf dem Trainingsdatensaz trainiert. Die Performance des Modells wird auf dem Validierungsset überwacht.

Epoche 1:
eval_loss: 1.1873277425765991
eval_precision: 0.10313447927199192
eval_recall: 0.2456896551724138
eval_f1: 0.13425925925925927
eval_accuracy: 0.6966292134831461

Epoche 2:
eval_loss: 0.9331737756729126
eval_precision: 0.16714285714285715
eval_recall: 0.24942129629629628
eval_f1: 0.19666725679383906

eval_accuracy: 0.7078651685393258

Epoche 3:
eval_loss: 0.8727896213531494
eval_precision: 0.20856060606060606
eval_recall: 0.31513409961685823
eval_f1: 0.2357282221467332
eval_accuracy: 0.6853932584269663

Epoche 4:
eval_loss: 0.8507784008979797
eval_precision: 0.19377125850340135
eval_recall: 0.2962962962962963
eval_f1: 0.21358825283243887
eval_accuracy: 0.6966292134831461

Der Loss-Wert des Modells sinkt während jeder Epoche, also jedem vollständigen Zyklus des Trainingdatensatzes, was darauf hindeutet, dass das Modell besser darin wird, die Testdaten vorherzusagen. Obwohl die Accuracy über die Epochen hinweg leicht schwank, bleibt sie im Bereich von etwa 0.69, was darauf schließen lässt, dass das Modell generell in der Lage ist, Testdaten relativ gut zu klassifizieren. Wenn man also sowohl Loss als auch Accuracy anschaut, könnte man meinen das Modell lernt erfolgreich. Dennoch ist der relativ hohe Accuracy-Wert nicht unbedingt ausschlaggebend für die Performance des Modells. Es könnte hier durchaus sein, dass die Klassenrepräsentation, wie im ersten Ansatz, durch die Natur der Daten etwas unausgeglichen ist und das Modell sich vor allem auf Labels, die überrepräsentiert sind fokussiert und diese entsprechend zuversichtlich vorhersagen kann. Da diese überrepräsentierten einen großen Teil der Daten ausmachen, ist die Anzahl der richtigen Entscheidungen, also die Accuracy natürlich sehr hoch. Der niedrige F1-score, der am Ende der Epochen bei 0.2 liegt, deutet aber darauf hin, dass das Modell Schwierigkeiten hat, einzelne Klassen, die eventuell unterrepräsentiert sind, vorherzusagen.
Es scheint also, dass sich das Modell an den häufig vorkommenden Klassen übertrainiert hat und nun Probleme hat, unbekannte beziehungsweise unterrepräsentierte Klassen zu generalisieren. Um das genauer zu interpretieren kann man sich Precision und Recall im einzelnen genauer anschauen. Die Precision, die zwar von der ersten zur letzten Epoche steigt, jedoch trotzdem mit 0.21 sehr niedrig ist, deutet darauf hin, dass viele Daten fälschlicherweise einem bestimmten Mittelwert zugeordnet wurden. Der niedrige Recall deutet darauf hin, dass das Modell Schwieirigkeiten damit hat, tatsächlich alle relevanten Instanzen einer Klasse zu erfassen. Diese Diskrepanz von Precision und Recall deutet weiter darauf hin, dass das Modell spezifische Klassen übetrainiert hat und somit nicht auf einzelne Klassen generalisieren kann. Insgesamt zeigt das Modell zwar Anzeichen des Lernens, jedoch weist der niedrige F1-Score darauf hin, dass die Leistung verbessert werden sollte, um alle Klassen ausgewogen klassifizieren zu können.
Nachdem wir durch die Verlängerung der Abgabefrist noch mit den Daten der

anderen Gruppen arbeiten konnten, sind wir schließlich in der Datei *B001_cleaned* auf folgende Ergebnisse gekommen:

Epoche 1:
eval_loss: 2.2061
eval_precision: 0.013157894736842105
eval_recall: 0.125
eval_f1: 0.02380952380952381
eval_accuracy: 0.10526315789473684

Epoche 2:
eval_loss: 2.2050
eval_precision: 0.013157894736842105
eval_recall: 0.125
eval_f1: 0.02380952380952381
eval_accuracy: 0.10526315789473684

Epoche 3:
eval_loss: 2.2045
eval_precision: 0.013157894736842105
eval_recall: 0.125
eval_f1: 0.02380952380952381
eval_accuracy: 0.10526315789473684

Epoche 4:
eval_loss: 2.2117
eval_precision: 0.013157894736842105
eval_recall: 0.125
eval_f1: 0.02380952380952381
eval_accuracy: 0.10526315789473684

Hier kann man an jedem Wert erkennen, dass sich das Modell nach der ersten Epoche nicht mehr verbessert. Es ist also nicht in der Lage, Daten angemessen zu generalisieren oder sich Muster anzueignen. Dies könnte daran liegen, dass wir nur auf einen Bruchteil der Daten zugreifen konnten, der bereits vorverarbeitet war. Der andere Teil wurde beim erstellen des Datensatzes als nicht dokumentiert erkannt. So fehlen dem Modell wahrscheinlich ausreichende Daten, um erfolgreich trainiert zu werden.

3 Fazit

In diesem Report wurde die Bearbeitung der Klassifikationsaufgabe im Rahmen des AES-Seminars detailliert beschrieben.

Wir haben hierbei zwei verschiedene Herangehensweisen aufgeführt: Die erste basiert auf der Klassifikation des Datensatzes anhand von Flesch-Readability-Scores, die zweite nutzt ein DistilBERT-Modell für die Vorhersage der Mittelwerte MW_B001 aus der Excel-Tabelle. In beiden Ansätzen wurde der Daten-

satz vorverarbeitet, indem Essays in Trainings- und Testsets aufgeteilt wurden. Im erstem Ansatz wurden die Essays außerdem gereiningt und ungültige Daten entfernt.

Die Modelle wurden anhand von Evaluationsmetriken wie Accuracy, Precision, Recall und/oder F1-Score beurteilt. Diese Metriken haben uns geholfen, einen Überblick über die Leistungsfähigkeit der Modelle zu bekommen und diese zu bewerten.

Beide Ansätze haben gewisse Erfolge erzielt, es gab aber auch viele Schwierigkeiten, wie beispielsweise Overfitting und Generalisierung auf unterrepräsentierte Klassen, durch den unausgewogenen Datensatz. Auch, dass wir während der Bearbeitung keinen Zugriff auf die Daten anderer Gruppen hatten, die bei der Bereinigung der Essays geholfen hätten, erschwerte vorerst das Vorgehen. Nachdem wir mit diesen Daten erhalten haben und damit im zweiten Ansatz weitergearbeitet haben, gab es aber hier nur einen Bruchteil der Essays, die annotiert waren und das Modell somit nicht erfolgreich lernen konnte und noch schlechter abschnitt als zuvor.

Insgesamt lässt sich aus den Ergebnissen des Berichts schließen, dass die Klassifikationsaufgabe im Rahmen des AES-Projekts vielseitige Herausforderungen mit sich gebracht hat und die Modelle für die Zukunft weiterer Optimierung bedürfen, um bessere Ergebnisse und eine tatsächliche Benotung der Essays zu erreichen.

References

Alake, R. (2023). *Loss functions in machine learning explained*. https://www.datacamp.com/tutorial/loss-function-in-machine-learning

D, E. (2019). Accuracy, recall & precision. *Medium*. https://medium.com/@erika.dauria/accuracy-recall-precision-80a5b6cbd28d

Heloir, H. (2023). A beginner comprehensive understanding of precision, recall, and f1 score: Demystifying key metrics in machine learning evaluation. *Medium*. https://medium.com/data-and-beyond/a-beginner-comprehensive-understanding-of-precision-recall-and-f1-score-demystifying-key-metrics-58cb3a2619e

HuggingFace. (2020). A great new dataset. https://huggingface.co/docs/datasets/main/en/dataset_script

HuggingFace. (2024a). *Text classification*. Retrieved February 5, 2024, from https://huggingface.co/docs/transformers/en/tasks/sequence_classification

HuggingFace. (2024b). *Transformers documentation*. Retrieved February 5, 2024, from https://huggingface.co/docs/transformers/en/task_summary

Klein, B. (n.d.). *Einführung in maschinelles lernen mit python*. https://www.python-kurs.eu/maschinelles_lernen_mit_python.php

Pratama, H. Y. (2022). Understanding the concept behind accuracy. *Medium*. https://medium.com/data-folks-indonesia/understanding-the-concept-behind-accuracy-fd076a2eb033

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). Distilbert, a distilled version of bert: Smaller, faster, cheaper and lighter.

van de Rakt, M. (2019). *The flesch reading ease score: Why and how to use it*. https://yoast.com/flesch-reading-ease-score/